Draft version November 30, 2024
Typeset using LaTeX **twocolumn** style in AASTeX631

GALAH: Clasificación de Componentes, Predicción de Abundancias Químicas y Edad Estelar en la Vía Láctea

Pablo Díaz[1]

[1] *Pontificia Universidad Católica de Chile*

ABSTRACT

Contexto. Estudios recientes con encuestas como GALAH y APOGEE han avanzado en la comprensión de la formación de la Vía Láctea mediante la relación entre abundancias químicas y edad estelar. El uso de relojes químicos, como [Y/Mg]-edad, junto con técnicas de aprendizaje automático, ha permitido mejorar las estimaciones de edad y comprender mejor la evolución química del disco galáctico

Objetivos. Mediante técnicas de aprendizaje automático, crear modelos predictivos capaces de deducir clasificación estelar dentro de la Vía Láctea, abundancia [Mg/Fe] (proxy de elementos α) y edad estelares únicamente a partir de datos de entrenamiento, que en principio no se encuentran correlacionados directamente.

Métodos. Usando los datos de GALAH DR4, se hizo una preparación de los datos que incluyó un filtro por flags de calidad, eliminación de outliers, y elección de columnas específicas según la variable a testear, para luego emplear la técnica de Random Forest para el entrenamiento de los distintos modelos. Para la obtención del mejor modelo se priorizó la maximización de alguna de las métricas asociadas mediante la variación de los hiperparámetros de cada árbol.

Resultados. Fue posible establecer propiedades físicas de la MW en base a las predicciones de los modelos entrenados. En cuanto al modelo de clasificación de componentes, sus parámetros de relevancia conducen a características estelares conocidas para estrellas del disco delgado y grueso; alta metalicidad y mayor proporción de elementos α respectivamente. De forma análoga, en base a las predicciones de [Mg/Fe] fue posible establecer una correlación con la metalicidad, y se confirmó la correlación negativa entre [Y/Fe] y la edad, al contrario de elementos α que siguen una tendencia creciente, únicamente a partir de un modelo entrenado a partir de abundancias.

Conclusión. Mediante técnicas de aprendizaje automático se logró dar una descripción adecuada de los distintos parámetros implicados dentro de la Vía Láctea, como abundancias, edades estelares, así como también la clasificación de sus componentes.

1. INTRODUCCIÓN

La formación de la Milky Way (MW) y su evolución temporal son interrogantes vigentes a día de hoy que enfrenta la astrofísica. La Arqueología Galáctica (Freeman & Bland-Hawthorn 2002) está experimentando una revolución en su intento por responder a estas preguntas, gracias al surgimiento de Gaia (Gaia Collaboration et al. 2016), que ha permitido una gran cantidad de nuevos descubrimientos sobre la estructura, formación y evolución de la Galaxia (Hayden et al. 2022). En este contexto, el sondeo GALAH, con su cuarta liberación de datos (DR4), aporta medidas de abundancias químicas de casi un tercio de los elementos de la tabla periódica. Este esfuerzo refuerza el objetivo del chemical tagging, que busca identificar estrellas formadas juntas mediante su composición química (De Silva et al. 2015). Con los datos del DR4, se han implementado innovaciones clave, como un enfoque híbrido de síntesis espectral y redes neuronales que permiten analizar un 95% del espectro estelar. Esto ha llevado a avances como la estimación precisa de abundancias de 32 elementos, incluidas moléculas como C_2 y CN, y parámetros estelares globales. Al integrar edades estelares, órbitas y química, GALAH ha desvelado hitos, como la fusión entre la MW y otra galaxia hace $8 - 10$ Gyr (Belokurov et al. 2018; Helmi et al. 2018), un descubrimiento que redefinió paradigmas sobre la formación galáctica.

Las estrellas son trazadores clave para estudiar la Vía Láctea, ya que conservan en su composición química las huellas del medio donde se formaron. Aunque métodos como el ajuste de isócronas o la astrosismología permiten estimar edades estelares, estos están limitados a ciertas regiones del diagrama Hertzsprung-Russell o a

áreas específicas del cielo (Borucki et al. 2010). Avances recientes emplean proxies químicos, como las relaciones [α/Fe] y los elementos del proceso s (e.g., [Y/Mg] o [Y/Al]), para determinar edades estelares y radios de nacimiento (Spina et al. 2016; Nissen & Schuster 2010). Estos proxies han demostrado ser útiles, especialmente para las poblaciones del disco delgado y grueso, donde las tendencias químicas difieren según la edad y la metalicidad (e.g., Bensby et al. (2017)).

De acuerdo con estudios recientes, las relaciones entre las abundancias químicas y la edad estelar, como la relación [Y/Mg]-edad, están emergiendo como herramientas poderosas para la datación de las estrellas, ya que pueden ofrecer estimaciones precisas de la edad a partir de las abundancias químicas. Por ejemplo, Casali et al. (2020) han encontrado que la relación [Y/Mg] no es universal y depende de la metalicidad, un factor clave al aplicar el método de los relojes químicos en diferentes poblaciones estelares. Este hallazgo resalta la importancia de considerar la variabilidad de las relaciones edad-abundancia, especialmente cuando se aplican a diferentes regiones galácticas, como el disco delgado y grueso, lo que complementa la información proporcionada por otros proxies químicos como [α/Fe].

Además, el uso de datos de grandes encuestas espectroscópicas, como los proporcionados por GALAH (De Silva et al. 2015) y APOGEE (Majewski et al. 2017), ha permitido estudiar de manera más precisa las relaciones entre la edad y las abundancias químicas en una gran muestra de estrellas. A través de métodos de aprendizaje automático y análisis bayesiano, como los utilizados por Hayden et al. (2022) y otros, se ha avanzado en la capacidad de estimar edades de estrellas con alta precisión, lo que expande enormemente el número de estrellas con edades conocidas y mejora nuestra comprensión de la evolución química del disco galáctico. Estos avances, combinados con la capacidad de estudiar las poblaciones estelares a gran escala, permiten un enfoque más robusto para entender la formación y evolución de la Vía Láctea, especialmente en lo que respecta a las interacciones entre edad, metalicidad y los procesos nucleosintéticos involucrados.

El objetivo de este trabajo es usar los datos provistos por GALAH DR4 para una respuesta a estas interrogantes desde un enfoque distinto. El algoritmo empleado del mismo será mediante el uso de una técnica de aprendizaje automática denominada Random Forest (RF). De esta forma, se buscará la creación de modelos capaces de predecir la componente dentro de la MW a la que pertenece una estrella, junto con la abundancia [Mg/Fe] y una estimación de edad únicamente a partir de abundancias químicas. Se corroborará además si dichas predicciones coinciden con correlaciones físicas entre distintos parámetros de la galaxia y que se puede concluir a partir de estudios previos.

2. DATOS

Se recopilaron datos de más de 900000 estrellas de la MW, usando catálogos que conforman parte del Data Release 4 de GALAH, que contiene distintos parámetros estelares, así también como abundancias y flags que cuantifican la confiabilidad de dichos parámetros (Buder et al. 2024). Cabe mencionar además que muchos de los parámetros espectroscópicos estelares contenidos en GALAH DR4 los catálogos K2-HERMES (Wittenmyer et al. 2018), TESS-HERMES (Sharma et al. 2018) generados a partir del instrumento High Efficiency and Resolution Multi-Element Spectrograph (HERMES), el cual es un espectrógrafo multifibra de alta resolución (R $\sim$ 28000) montado en el Telescopio Anglo Australiano (AAT) de 3.9 metros. HERMES cubre 4 rangos de longitudes de onda diferentes (4713 $-$ 4903 Å, 5648 $-$ 5873 Å, 6478 $-$ 6737 Å, 7585 $-$ 7887 Å) con tal de maximizar el número de abundancias elementales medibles (Hayden et al. 2022). La precisión de las abundancias individuales [X/Fe] es del orden de $\sim$ 0.5 dex, mientras que el error en velocidades radiales (una de las componentes orbitales de cada estrella) es de $\sim$ 100 ms^{-1} (Zwitter et al. 2018).

2.1. *Preparación de los datos*

Se requirió hacer una preparación de los datos previa al entrenamiento de los modelos. En primer lugar, se usaron las flags de calidad `flag_sp=0` y `snr_px_ccd3 > 30`, la primera para asegurar que las variables espectroscópicas a entrenar sean confiables y la segunda para establecer una señal a ruido por píxel mínima de 30 dentro de la cámara del instrumento. En adición, se hizo una inspección manual de `NaN` para cada una de las abundancias del catálogo, y se descartaron de forma inmediata las abundancias [Rb/Fe], [Sr/Fe], [Zr/Fe], [Mo/Fe], [Ru/Fe], [La/Fe], [Ce/Fe], [Sm/Fe] y [Eu/Fe] por presentar una cantidad de `NaNs` considerables con respecto a los otros elementos. Este criterio de eliminación es importante, pues posterior a ello se aplicó la flag de calidad `flag_X_fe = 0` para rescatar únicamente aquellas abundancias confiables; en caso de no haber realizado la eliminación anterior, la cantidad de datos se habría reducido sustancialmente.

Tras este filtro, las abundancias que se utilizarán a lo largo de este trabajo son: [C/Fe], [N/Fe], [O/Fe], [Na/Fe], [Mg/Fe], [Al/Fe], [Si/Fe], [K/Fe], [Ca/Fe], [Sc/Fe], [Ti/Fe], [V/Fe], [Cr/Fe], [Mn/Fe],

[Co/Fe], [Ni/Fe], [Cu/Fe], [Zn/Fe], [Y/Fe], [Ba/Fe] y [Nd/Fe]. En cuanto a las otras columnas del catalogo, fueron seleccionadas todas, incluyendo parámetros espectroscópicos, componentes orbitales e identificadores estelares.

Finalmente, observando las distribuciones de las columnas (veáse la Figura 1) es posible apreciar que existe presencia de outliers dentro los parámetros bajo estudio. Entre los dos métodos de eliminación de outliers contemplados, sigmma clipping a 5σ y por percentiles 2.5 y 97.5, se prefirió utilizar sigma clipping debido a que con este método preservamos una mayor cantidad de datos que si utilizaramos percentiles, donde podemos apreciar de la propia Figura 1 para la temperatura efectiva por ejemplo el recorte implicado entre una y la otra. Un hecho importante es que este proceso de eliminación de outliers no se realizó de forma general a todos los parámetros del catálogo, más bien se realiza sobre la selección de columnas específicas para los entrenamientos de los distintos modelos llevados a cabo en la Sección 3, pues estas columnas pueden ir variando dadas las variables implicadas en cada entrenamiento para construir el modelo de predicción.

Finalizada esta preparación previa, se generó un nuevo catálogo a partir de todas las consideraciones mencionadas en esta sección, y estos corresponden a los datos que serán utilizados durante el análisis para la construcción de modelos predictivos.

3. ANÁLISIS Y DISCUSIÓN

Se emplearan técnicas de machine learning para establecer una relación entre las distintas características medidas para las estrellas de la MW, mediante la creación de un modelo predictivo capaz de inferir ciertas variables en función de datos de entrada. En específico, se crearan modelos para caracterizar a las estrellas dentro del halo, disco grueso o disco delgado, predecir la abundancia de [Mg/Fe] y encontrar relojes químicos.

3.1. *Random Forest*

Durante el análisis se utilizará RF, una técnica de aprendizaje automático de ML para buscar propiedades y explorar el uso de ciertas características para predecir otra mediante un modelo generado. Se utiliza tanto para tareas de clasificación como de regresión y es conocido por su robustez frente al sobreajuste y su capacidad para manejar relaciones complejas entre las características (Hastie et al. 2008). Este modelo crea múltiples árboles de decisión independientes entrenados con diferentes subconjuntos de los datos, combinando sus resultados para obtener una predicción final más precisa. En el caso de clasificación, se usa el voto mayoritario entre los árboles, mientras que para regresión se calcula el promedio de las predicciones.

El modelo mide la calidad de las divisiones en los árboles mediante una métrica, que depende del tipo de problema. Estas métricas ayudan a los árboles a encontrar las divisiones que maximicen la información obtenida de los datos.

El rendimiento de un RF depende de varios hiperparámetros clave que controlan su comportamiento. Entre ellos, el número de árboles en el bosque mejora la precisión pero aumenta el costo computacional. Limitar la profundidad de los árboles y ajustar el número mínimo de muestras por nodo ayuda a evitar el sobre ajuste. Además, el tamaño del subconjunto de características considerado en cada división influye en la diversidad del bosque y la estabilidad de las predicciones (Hastie et al. 2008; Piryonesi & El-Diraby 2020).

3.2. *Clasificación Estelar*

Para poder realizar el entrenamiento por medio de un RF se requiere separar con anterioridad a cada estrella en cada una de las componentes de la MW para poder establecer una muestra target de referencia. Uno de los modelos ampliamente utilizados consiste en la descomposición cinemática de las componentes de la MW por medio del diagrama de Toomre (Da Silva et al. 2023; Bensby et al. 2014; Venn et al. 2004). Este consiste en un espacio de velocidades donde se relaciona la cuadratura de la velocidades espaciales radial (U) y vertical (W) como función de la velocidad a lo largo del disco de rotación (V). Si definimos la velocidad total en este espacio de velocidades como

$$V_{\rm tot} = \sqrt{U^2 + V^2 + W^2}$$

tenemos como primera aproximación que las estrellas con $V_{\rm tot} < 50$ km s^{-1} pertenecen al disco delgado, mientras que estrellas con $70 < V_{\rm tot} < 180$ km s^{-1} corresponden principalmente a estrellas del disco grueso (Bensby et al. 2014; Nissen 2004). Estrellas con alta velocidad $V_{\rm tot} > 180$ km s^{-1} son asignadas a la población estelar del halo (Nissen & Schuster 2010). En la Figura 2 se muestra esta clasificación para todas las estrellas que estamos considerando. Cabe destacar que existe una proporción de estrellas entre la región intermedia $50 < V_{\rm tot} < 70$ km s^{-1} que no forman parte de ninguna componente: este es únicamente un criterio para poder separar apropiadamente estrellas pertenecientes al disco delgado y grueso, pues dada la gran cantidad de estrellas en ambas regiones (en comparación con el halo) y el acotado rango de velocidades, se considera una región de overlap. Por ende, para posteriores análisis se debe

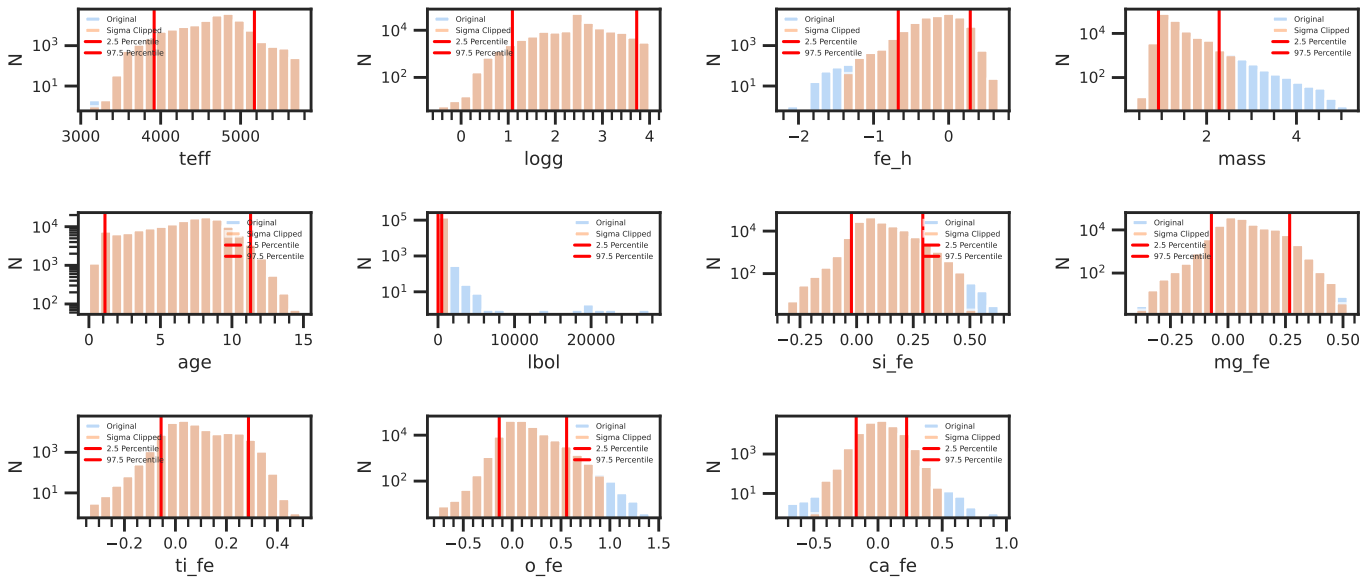


Figure 1: Histograma de las distribuciones de algunos de los parámetros dentro del catálogo. Se superpone la distribución original (en celeste) con una distribución que selecciona únicamente aquellos valores dentro de un rango de 5σ, producto de haber hecho sigma clipping (en naranja). Adicionalmente se muestran los rangos de corte (en rojo) para los percentiles 2.5 y y 97.5.

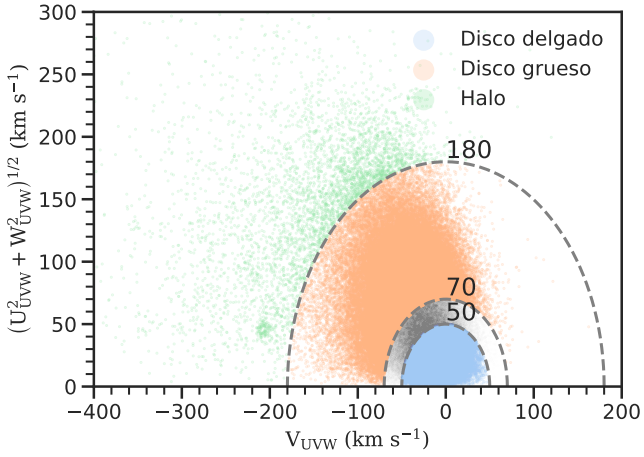


Figure 2: Diagrama de Toomre para las estrellas consideradas. Se demarcan los radios correspondientes a $V_{\rm tot} = 50, 70, 180$ km s^{-1}. Tomando en cuenta el criterio de clasificación mencionado en Da Silva et al. (2023) se logró separar las estrellas en las distintas componentes de la MW: en verde estrellas del halo, naranja disco grueso y celeste disco delgado. Las estrellas en gris no se catalogan en ninguna estructura debido a ser una región de overlap entre disco grueso y delgado.

corroborar que la data de entrenamiento no contenga estas estrellas sin clasificar.

3.2.1. *Creación de Modelos de Clasificación*

Hecha esta clasificación previa, se continuó con la creación de modelos usando un RF de clasificación para predecir a que componente de la MW pertenece una estrella en particular dado ciertos parámetros. En otras palabras, se requiere crear 3 RFs, uno para cada componente galáctica, de forma que la clasificación se hace mediante una elección binaria para cada modelo en específico.

Sin embargo, tras la clasificación hecha a partir del diagrama de Toomre, los datos resultantes presentan una cantidad considerablemente baja de estrellas en el halo ($\sim 2\%$) en relación a estrellas que forman parte del disco grueso y delgado. Esto se traduce en un desbalanceo de clases, lo que implica que una o más clases están sobrerrepresentadas en los datos de entrenamiento en comparación con otras, lo que puede hacer que el modelo tenga un sesgo hacia las clases mayoritarias. Para solucionar esto se optó por un balanceo hacia la clase mayoritaria, es decir, crear copias de las instancias que corresponden al halo hasta llegar a una proporción razonable de datos para cada una de las categorías.

Las variables seleccionadas para el entrenamiento del modelo fueron todas las abundancias listadas en la Sección 2.1 y todos los parámetros estelares (edad, temperatura efectiva, masa, luminosidad bolométrica, etc). Las componentes orbitales no deben ser consideradas pues es el proxy utilizado para crear las categorías en primer lugar.

Para cada uno de los tres modelos se evaluó su rendimiento usando tres métricas diferentes: Precission, Accuracy y Recall. Tomaremos como ejemplo el modelo que predice estrellas en el halo. La métrica clave a max-

Table 1: Primeros 3 parámetros más utilizados durante el entrenamiento de los modelos de clasificación estelar, ordenados de mayor a menor importancia (donde Parámetro 1 es el más importante).

Estructura	Parámetro 1	Parámetro 2	Parámetro 3
Halo	[Ti/Fe]	[Si/Fe]	[Fe/H]
Disco Delgado	[Fe/H]	[Ti/Fe]	[Mg/Fe]
Disco Grueso	[Si/Fe]	[Mg/Fe]	[Ti/Fe]

imizar debe ser el Recall pues al ser originalmente una clase minoritaria (si bien se hizo un balanceo, esto es tan sólo un sesgo) debemos tratar de minimizar la pérdida de más estrellas al considerar falsos negativos (estrellas del halo clasificadas erróneamente como no del halo). Por lo tanto, debemos ajustar los hiperparámetros del RF con tal de obtener el mejor Recall posible. En la Figura 3 se muestra como varían las distintas métricas para distintos hiperparámetros del RF: profundidad, número de árboles, split (número mínimo de muestras requeridas para dividir un nodo) y leaf (número mínimo de muestras que debe tener un nodo hoja). Notamos que tenemos un Recall casi estable en todos los casos, lo que nos indica que en general nuestro modelo está respondiendo bien en cuando a la detección de falsos negativos. Podemos fijar una profundidad de 15 para alcanzar su máximo, eso nos da un Recall del 99%.

Para el resto de categorías (disco grueso y delgado) el proceso es análogo, sólo debe considerarse que métrica maximizar. En este trabajo se optó por Accuracy como métrica principal, dado que la proporción de estrellas en disco grueso y delgado es similar, por ende buscamos penalizar de forma equivalentemente errores en ambas categorías. En la Figura 4 se muestran sus correspondientes matrices de confusión, tabla que resume el desempeño de un modelo de clasificación al comparar las predicciones con las etiquetas reales, permitiendo discernir entre verdaderos positivos (TP), falsos positivos (FP), verdaderos negativos (TN) y falsos negativos (FN).

RF cuantifica que parámetros de los datos de entrenamiento fueron más utilizados a la hora de hacer predicciones mediante una reducción de impureza (Piryonesi & El-Diraby 2020) que se calcula para determinar cuán eficaz fue esa división (como el índice de Gini o la ganancia de información). Los parámetros ordenados por importancia se encuentran tabulados en la Tabla 1,

3.2.2. *Interpretación*

Ahondemos el los parámetros de mayor relevancia de la Tabla 1 que nos entrega el modelo para cada estructura en particular. En Da Silva et al. (2023) se discute una segunda forma de clasificación estelar para disco grueso y delgado en base a su composición química, en específico, para las abundancias de elementos alpha [α/Fe]. Esta razón puede indicar qué tan rápidamente se formó una estrella y el tipo de supernova que enriqueció el gas circundante. Esta separación se hace entonces a partir de la distribución bimodal observada de las estrellas en las abundancias de los elementos α en función de la metalicidad, el plano [α/Fe] versus [Fe/H], que se usa con frecuencia para separar las poblaciones del disco fino y grueso (químicamente) en varios estudios espectroscópicos (Hayden et al. 2015; Recio-Blanco et al. 2014; Queiroz et al. 2023; Da Silva et al. 2023). En base a estos estudios, se concluye una abundancia de elementos α mayor en el disco grueso con respecto al disco delgado. Este comportamiento se corrobora de los modelos generados al contrastar con la Tabla 1, donde el modelo estableció como parámetros más importantes de predicción para el disco grueso justamente elementos α. Para disco delgado el parámetro más utilizado durante el entrenamiento fue la metalicidad [Fe/H], hecho esperable dado que las estrellas de esta región presentan alta metalicidad. Finalmente, en cuanto al modelo del halo destacan como parámetros elementos α, siendo el elemento menos importante la metalicidad. Este comportamiento guarda sentido ya que en particular, la metalicidad del halo es más baja en comparación a otras estructuras, por ende existe una mayor contribución en abundancias [α/Fe] que el modelo atribuye con más peso.

3.3. *Predicción de Abundancias* [Mg/Fe]

Se utilizó un RF de regresión para predecir la abundancia [Mg/Fe] dentro de la MW, dado que el target del entrenamiento es un parámetro continuo[1]. Para el entrenamiento del modelo se utilizaron todas las propiedades espectroscópicas y orbitales. Los únicos parámetros restringidos a considerar son las abundancias, donde se deben descartar las abundancias [α/Fe] pues [Mg/Fe] es un proxy para dichos elementos.

Las métricas que fueron consideradas para evaluar el rendimiento fueron R2 Score, RMS (Root Mean Squared Error) y MAE (Mean Absolute Error). En este trabajo se optó por maximizar R2 Score, un coeficiente robusto que mide la proporción de la variabilidad de la variable dependiente que es explicada por el modelo. En otras

[1] Para un RF de clasificación este target es discreto y tiene comportamiento binario.

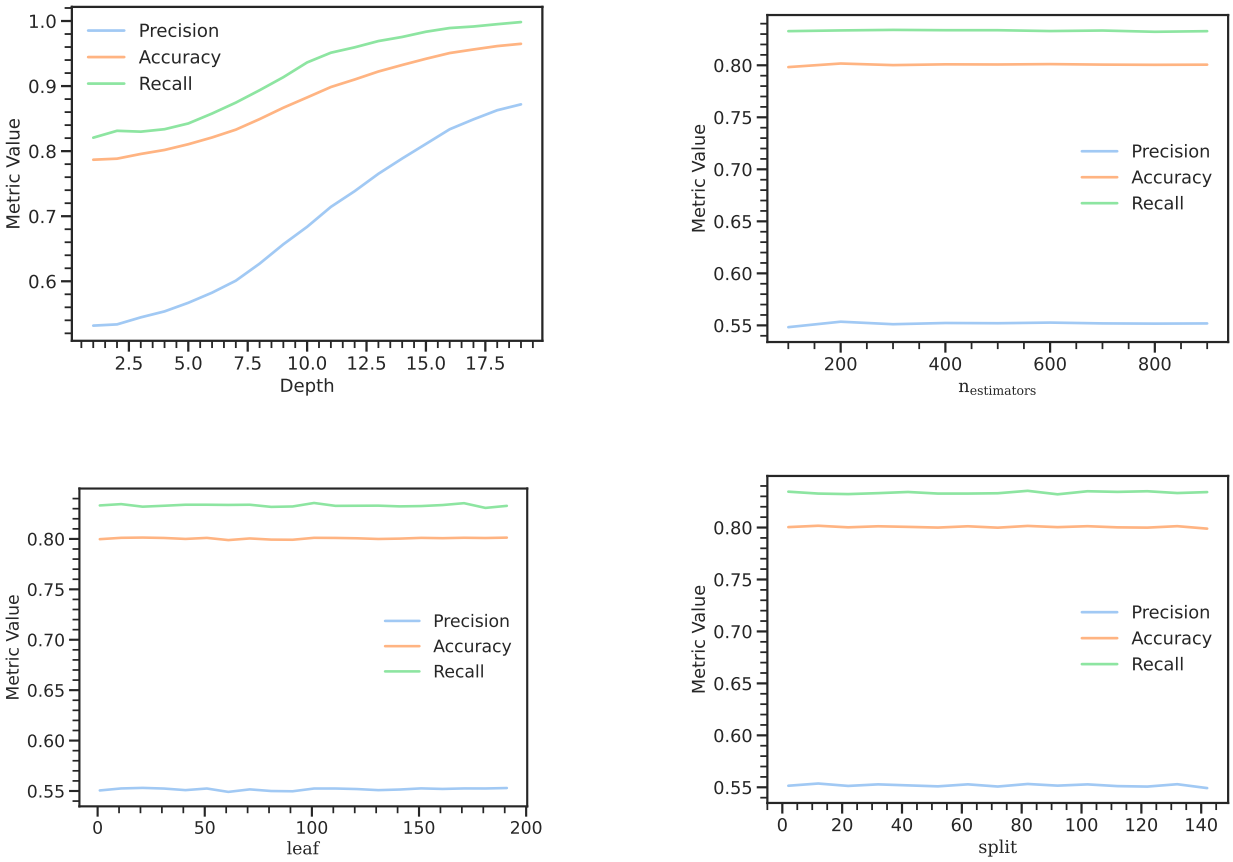


Figure 3: Métricas Recall, Precission y Acuraccy para el modelo predictor de componente en el halo para 4 hiperparámetros distintos en el RF: profundidad (superior izquierdo), número de árboles (superior derecho), leafs (inferior izquierdo) y splits (inferior derecho). En cada caso se varió un hiperparámetro mientras que los otros se mantenían constantes

palabras, indica cuán bien el modelo predice los valores observados en comparación con la media de los valores observados. Al igual que en la Sección 3.2.1, se maximizó esta métrica variando los hiperparámetros del RF y buscando la mejor combinación que maximice el R2 Score. En la Figura 5 se muestra el comportamiento de las métricas para una cierta profundidad del árbol (otros hiperparámetros no son mostrados, pero el análisis es análogo). Se evidencia que una profundidad 10 es suficiente para maximizar R2, que alcanza un valor de 0.78.

Entrenado el modelo, en la Figura 6 se muestra la distribución de la abundancia [Mg/Fe] predicha con respecto a la observada. Como es posible visualizar, se evidencia una clara correlación entre los valores predichos y observados, tendiendo a formar una recta (caso ideal, en este caso los valores predichos coinciden exactamente con el real), indicando un que el modelo es capaz de reproducir valores observados de [Mg/Fe] únicamente a partir de otras abundancias y parámetros estelares. Adicionalmente, al ordenar los parámetros según su uso para la predicción, es la metalicidad [Fe/H] con diferencia el parámetro más importante.

3.3.1. *Interpretación*

La variable con mayor importancia utilizada por el modelo corresponde a la metalicidad, hecho que se explica si ambas cantidades, [Mg/Fe] y [Fe/H] están correlacionadas. En concreto, en Shejeelammal et al. (2024) se menciona que al graficar [Mg/Fe] en función de la metalicidad se muestra una clara bimodalidad en la distribución de las estrellas del disco galáctico, evidenciando dos poblaciones: el disco grueso (high-α) y el disco delgado (low-α). A bajas metalicidades, estas dos poblaciones son claramente distinguibles, mientras que a metalicidades más altas ([Fe/H] $\geq$ 0), se vuelven indistinguibles. Este fenómeno ha sido identificado en varios estudios previos (por ejemplo, Reddy et al. (2006); Adibekyan et al. (2012)). La bimodalidad refleja la diferente evolución quimio-dinámica del disco

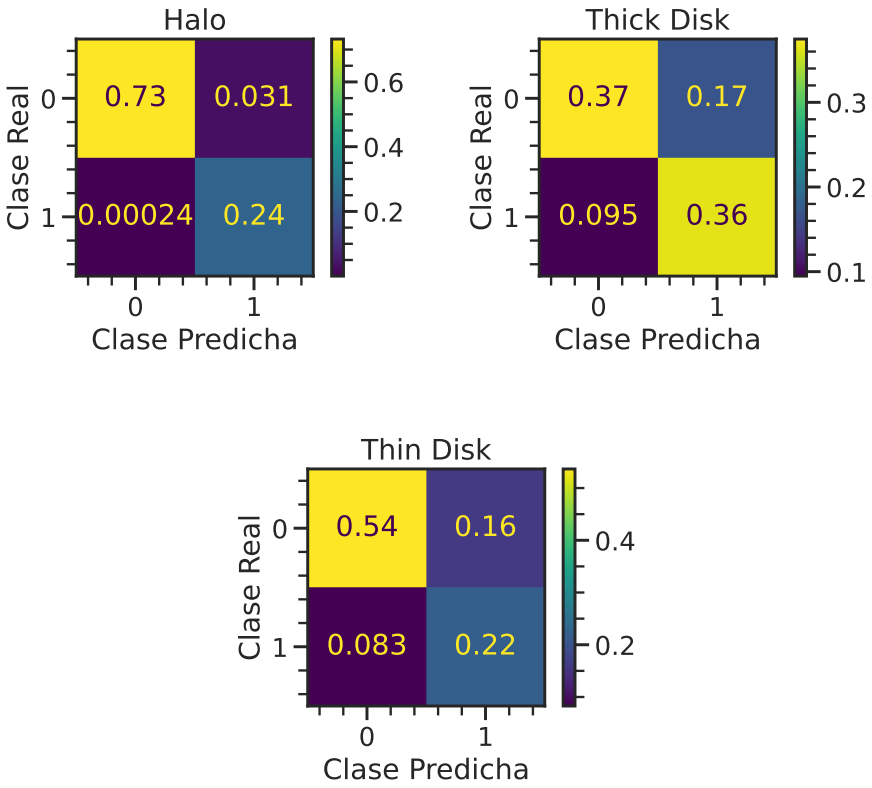


Figure 4: Matrices de confusión para los modelos predictores de clasificación de cada categoría.

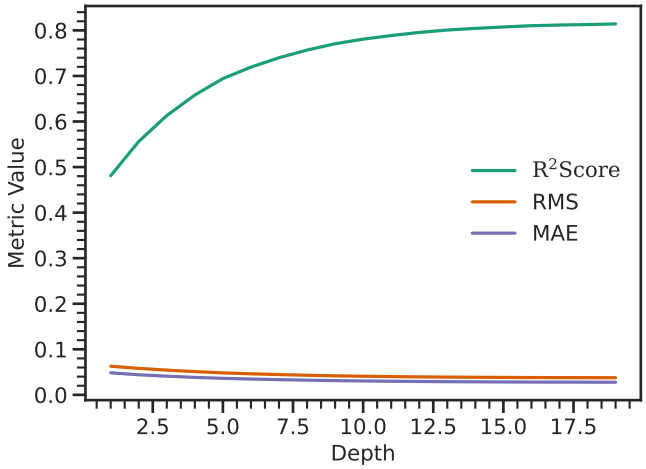


Figure 5: Comportamiento de la métricas consideradas para el modelo predictor de [Mg/Fe] en función de la profundidad del árbol.

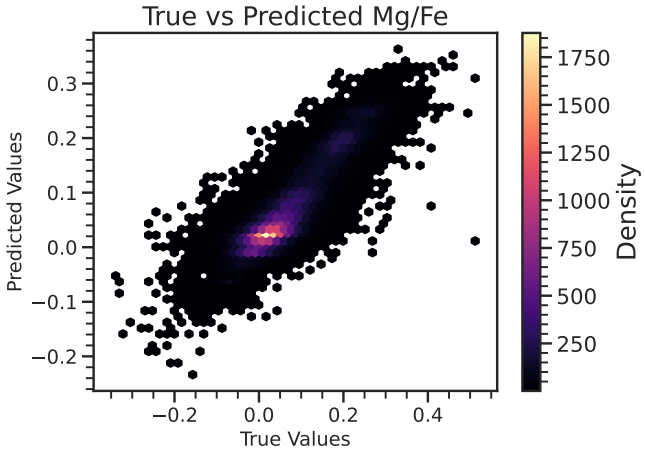


Figure 6: Distribución de valores predichos de [Mg/Fe] por el modelo en función de las abundancias reales.

galáctico: el disco grueso está compuesto por estrellas antiguas y empobrecidas en metales, mientras que el disco delgado está formado por estrellas más jóvenes y con menor enriquecimiento en elementos alfa (Fuhrmann 1998; Bensby et al. 2005). En realidad, este hecho ya fue discutido anteriormente en la Sección 3.2.2, donde se describió una segunda forma de clasificación para las componentes del disco galáctico en términos de las abundancias de los elementos α y la metalicidad. Mg propiamente tal también un elemento alpha, por lo que es razonable que el modelo haya utilizado como parámetro más importante la metalicidad para realizar las predicciones, pues ambas cantidades están correlacionadas.

3.4. *Medición de Relojes Químicos*

Finalmente, se empleó un último RF de regresión para estimar la edad aproximada de las estrellas dentro de la MW en base únicamente a las abundancias químicas observadas. Como target para el entrenamiento se seleccionó obviamente la edad de cada estrella, y como data a entrenar todas las abundancias. En adición, se uso como referencia el trabajo de Hayden et al. (2022) (que utiliza el mismo catálogo de estrellas) para el criterio de selección, se restringen las estrellas bajo estudio a aquellas con $T_{eff} < 6200$ K y metalicidades $-1.0 <$ [Fe/H] < 0.5 dex, donde la primera condición se realizó dado que se encontró con problemas significativos en las abundancias medidas para estrellas más calientes, y la segunda condición se impone para restringir el estudio al disco, ya que las relaciones edad-abundancia de cualquier objeto acrecionado, como el halo, siguen una historia de enriquecimiento diferente.

Nuevamente, se estudiaron las mismas métricas mencionadas en la Sección 3.3, dando especial énfasis en R2 Score, siendo la métrica a maximizar. En la Figura 7 se muestra el análisis de la métrica en función de la profundidad del árbol (para el resto de parámetros se procede de igual forma). Notamos que a partir de profundidad 5 alcanzamos el máximo de R2 Score, con un valor de 0.62. No fue posible maximizar más este valor, sin embargo al observar la distribución de edad predicha y observada en la Figura 8 notamos de todas formas una clara correlación, con densidades concentrándose a lo largo de una línea recta. Esto es un buen indicador para las predicciones hechas por el modelo. Finalmente, el parámetro más relevante a la hora del entrenamiento fue [Mg/Fe] y los abundancias de Y y C (en principio estos últimos dos no son muy confiables debido a que la métrica aún necesita perfeccionarse, pero veremos que esto puede argumentarse a partir de la Sección 3.4.1).

3.4.1. *Interpretación*

La aparición de las abundancias [Mg/Fe] y [Y/Fe] como uno de los parámetros más utilizados durante el entrenamiento no es circunstancial.

En primer lugar el Mg es un elemento α producido por supernovas de Tipo II (SNe II) en escalas de tiempo más cortas ($\leq 10^7$ años; e.g., Kobayashi et al. (2006)). Durante las primeras etapas de la evolución química, las SNe II fueron los principales contribuyentes de metales al medio interestelar. Por lo tanto, los elementos α presentan una tendencia positiva con la edad.

Por otro lado, el Y es un elemento del proceso s producido en estrellas de la rama asintótica gigante (AGB) de masa baja e intermedia, las cuales contribuyeron a la evolución química mucho más tarde en comparación con las SNe II. Como resultado, el Y muestra una tendencia negativa con respecto a las edades estelares (Nomoto et al. 2013; Karakas & Lattanzio 2014; Spina et al. 2016). Debido a estos diferentes orígenes y procesos de evolución química, la razón [Y/Mg] tiene una dependencia más pronunciada con las edades estelares (Sheejeelammal et al. 2024). Esto también se corresponde con la Figura 9 donde se muestran las 6 abundancias más importantes durante el entrenamiento del modelo. Si visualizamos, la abundancia de Y tiene una clara correlación negativa con la edad, por ende esto reafirma la hipótesis de una tendencia negativa conforme la edad, predicha en principio únicamente a partir de las abundancias químicas.

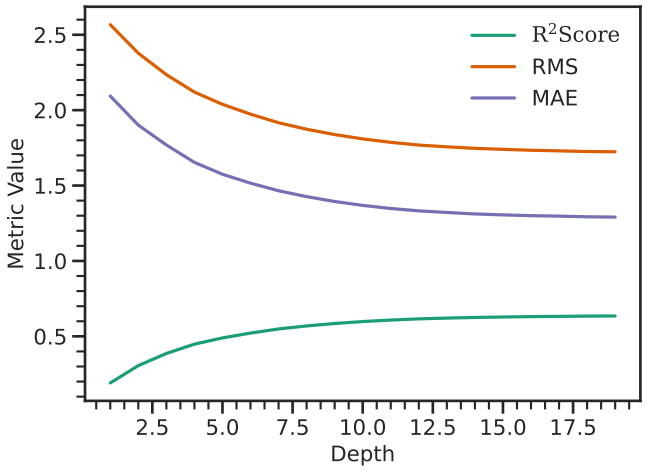


Figure 7: Comportamiento de la métricas consideradas para el modelo predictor de edad en función de la profundidad del árbol..

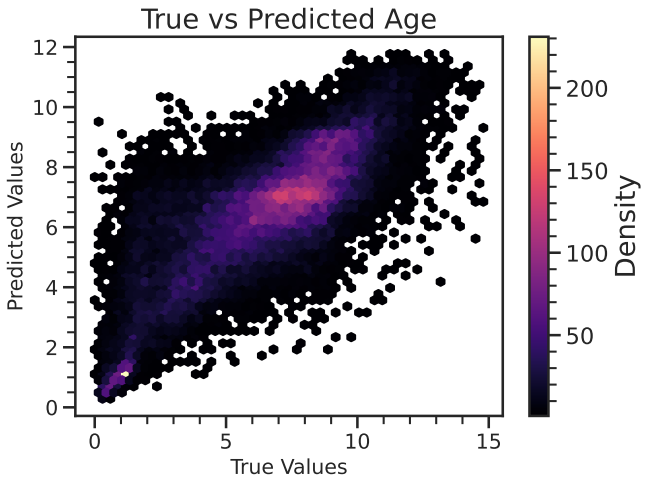


Figure 8: Distribución de valores predichos de edad por el modelo en función de las edades reales.

4. CONCLUSIÓN

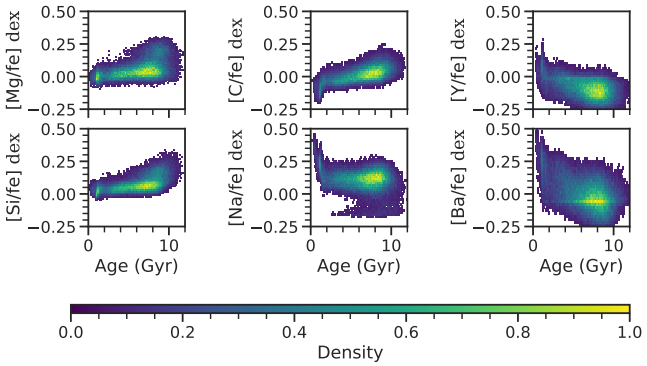


Figure 9: Distribución de abundancias en función de las edades (ambas cantidades obtenidas directamente desde los datos). Se muestran únicamente algunas de las abundancias más relevantes utilizadas por el modelo.

Se crearon modelos predictores mediante un entrenamiento provisto por RFs de categorización y regresivos para predecir distintas propiedades físicas de la MW, mediante la maximización de alguna de sus métricas. En primer lugar, fue posible entrenar modelos capaces de clasificar estrellas para una de las componentes estructurales de la MW. En base a los parámetros principales de entrenamiento, se logró confirmar características conocidas de cada estructura: disco delgado con metalicidad dominante, disco grueso con abundancias de elementos α en mayor proporción, y la pobre metalicidad del halo, que exacerba la presencia de abundancias [α/Fe] (aún siendo menor a las del disco grueso, sin embargo). Por otro lado, se construyó un modelo capaz de predecir eficazmente [Mg/Fe], hecho que fue corroborado en virtud a la correlación entre [Mg/Fe] y metalicidad discutida en Shejeelammal et al. (2024), siendo este último parámetro la variable de mayor importancia dentro del modelo predictor. Finalmente, fue posible estimar la edad de estrellas en la MW mediante abundancias químicas por medio de otro modelo entrenado. A partir de estas predicciones, fue posible concluir hechos ya mencionados en otros estudios como Nomoto et al. (2013); Karakas & Lattanzio (2014); Hayden et al. (2022), como la correlación negativa entre [Y/Fe] y la edad, o la tendencia positiva de elementos α con la edad, hecho que se corrobora en los gráficos de abundancia en función de la edad para las estrellas del propio catálogo.

REFERENCES

Adibekyan, V. Z., Delgado Mena, E., Sousa, S. G., et al. 2012, Astronomy & Astrophysics, 547, A36, doi: 10.1051/0004-6361/201220167

Belokurov, V., Erkal, D., Evans, N. W., Koposov, S. E., & Deason, A. J. 2018, Monthly Notices of the Royal Astronomical Society, 478, 611, doi: 10.1093/mnras/sty982

Bensby, T., Feltzing, S., Lundström, I., & Ilyin, I. 2005, Astronomy & Astrophysics, 433, 185, doi: 10.1051/0004-6361:20040332

Bensby, T., Feltzing, S., & Oey, M. S. 2014, Astronomy and Astrophysics, 562, A71, doi: 10.1051/0004-6361/201322631

Bensby, T., Feltzing, S., Gould, A., et al. 2017, Astronomy & Astrophysics, 605, A89, doi: 10.1051/0004-6361/201730560

Borucki, W. J., Koch, D., Basri, G., et al. 2010, Science, 327, 977, doi: 10.1126/science.1185402

Buder, S., Kos, J., Wang, E. X., et al. 2024, The GALAH Survey: Data Release 4, arXiv. http://arxiv.org/abs/2409.19858

Casali, G., Spina, L., Magrini, L., et al. 2020, Astronomy & Astrophysics, 639, A127, doi: 10.1051/0004-6361/202038055

Da Silva, M. P., De Lima, M. M. F., Velloso, E. N., & Do Nascimento, J.-D. 2023, The Astrophysical Journal, 958, 32, doi: 10.3847/1538-4357/acfc3f

De Silva, G. M., Freeman, K. C., Bland-Hawthorn, J., et al. 2015, Monthly Notices of the Royal Astronomical Society, 449, 2604, doi: 10.1093/mnras/stv327

Freeman, K., & Bland-Hawthorn, J. 2002, Annual Review of Astronomy and Astrophysics, 40, 487, doi: 10.1146/annurev.astro.40.060401.093840

Fuhrmann, K. 1998, Astronomy and Astrophysics, 338, 161. https://ui.adsabs.harvard.edu/abs/1998A&A...338..161F

Gaia Collaboration, Brown, A. G. A., Vallenari, A., et al. 2016, Astronomy & Astrophysics, 595, A2, doi: 10.1051/0004-6361/201629512

Hastie, T., Tibshirani, R., & Friedman, J. 2008, The elements of statistical learning: data mining, inference, and prediction, 10th edn., Springer series in statistics (New York, NY: Springer)

Hayden, M. R., Bovy, J., Holtzman, J. A., et al. 2015, The Astrophysical Journal, 808, 132, doi: 10.1088/0004-637X/808/2/132

Hayden, M. R., Sharma, S., Bland-Hawthorn, J., et al. 2022, Monthly Notices of the Royal Astronomical Society, 517, 5325, doi: 10.1093/mnras/stac2787

Helmi, A., Babusiaux, C., Koppelman, H. H., et al. 2018, Nature, 563, 85, doi: 10.1038/s41586-018-0625-x

Karakas, A. I., & Lattanzio, J. C. 2014, Publications of the Astronomical Society of Australia, 31, e030, doi: 10.1017/pasa.2014.21

Kobayashi, C., Umeda, H., Nomoto, K., Tominaga, N., & Ohkubo, T. 2006, The Astrophysical Journal, 653, 1145, doi: 10.1086/508914

Majewski, S. R., Schiavon, R. P., Frinchaboy, P. M., et al. 2017, The Astronomical Journal, 154, 94, doi: 10.3847/1538-3881/aa784d

Nissen, P. E. 2004, 154, doi: 10.48550/arXiv.astro-ph/0310326

Nissen, P. E., & Schuster, W. J. 2010, Astronomy and Astrophysics, 511, L10, doi: 10.1051/0004-6361/200913877

Nomoto, K., Kobayashi, C., & Tominaga, N. 2013, Annual Review of Astronomy and Astrophysics, 51, 457, doi: 10.1146/annurev-astro-082812-140956

Piryonesi, S. M., & El-Diraby, T. E. 2020, Journal of Transportation Engineering, Part B: Pavements, 146, 04020022, doi: 10.1061/JPEODX.0000175

Queiroz, A. B. A., Anders, F., Chiappini, C., et al. 2023, Astronomy and Astrophysics, 673, A155, doi: 10.1051/0004-6361/202245399

Recio-Blanco, A., de Laverny, P., Kordopatis, G., et al. 2014, Astronomy and Astrophysics, 567, A5, doi: 10.1051/0004-6361/201322944

Reddy, B. E., Lambert, D. L., & Prieto, C. A. 2006, Monthly Notices of the Royal Astronomical Society, 367, 1329, doi: 10.1111/j.1365-2966.2006.10148.x

Sharma, S., Stello, D., Buder, S., et al. 2018, Monthly Notices of the Royal Astronomical Society, 473, 2004, doi: 10.1093/mnras/stx2582

Shejeelammal, J., Meléndez, J., Rathsam, A., & Martos, G. 2024, Astronomy & Astrophysics, 690, A107, doi: 10.1051/0004-6361/202449669

Spina, L., Meléndez, J., Karakas, A. I., et al. 2016, Astronomy & Astrophysics, 593, A125, doi: 10.1051/0004-6361/201628557

Venn, K. A., Irwin, M., Shetrone, M. D., et al. 2004, The Astronomical Journal, 128, 1177, doi: 10.1086/422734

Wittenmyer, R. A., Sharma, S., Stello, D., et al. 2018, The Astronomical Journal, 155, 84, doi: 10.3847/1538-3881/aaa3e4

Zwitter, T., Kos, J., Chiavassa, A., et al. 2018, Monthly Notices of the Royal Astronomical Society, 481, 645, doi: 10.1093/mnras/sty2293